

Taller — Regresión Exponencial y Regresión Logística

Caso de estudio: MiBolsillo — una fintech colombiana en expansión

Modalidad	Individual o en parejas (según indicación del profesor)
Formato de entrega	Jupyter Notebook (.ipynb) nuevo, con código, gráficos y celdas de texto
Herramientas	Python (scikit-learn, statsmodels, pandas, matplotlib/seaborn)
Ponderación	Ver rúbrica de evaluación al final de este documento

Contexto del caso

MiBolsillo es una fintech colombiana, con sede en Medellín, que ofrece una billetera digital y, desde hace unos meses, microcréditos de bajo monto para sus usuarios. La compañía atraviesa un momento decisivo: acaba de lanzar una campaña de referidos que disparó la adopción de la app, y al mismo tiempo necesita afinar su modelo de riesgo crediticio antes de escalar su producto de microcréditos a todo el país.

Te unes al equipo de Data Science de MiBolsillo para resolver dos preguntas de negocio completamente distintas, que compañía necesita responder esta semana. Tu tarea es aplicar los dos modelos que trabajamos en clase — regresión exponencial y regresión logística — para responder cada una.

Objetivo de aprendizaje

Reconocer qué tipo de modelo corresponde a cada tipo de variable respuesta en un contexto de negocio nuevo.

Ajustar e interpretar un modelo de regresión exponencial sobre una serie de crecimiento.

Ajustar e interpretar un modelo de regresión logística sobre una variable de riesgo binaria, incluyendo odds ratios.

Comunicar los resultados de ambos modelos en un lenguaje claro para la gerencia de MiBolsillo.

Instrucciones generales

Para cada una de las dos partes de este taller, tu notebook debe incluir, como mínimo, las siguientes secciones:

1. Planteamiento del problema: describe en tus propias palabras qué se quiere responder y por qué el tipo de variable respuesta exige el modelo correspondiente (exponencial o logístico).
2. Análisis exploratorio: al menos una visualización que soporte tu elección de modelo.
3. Ajuste del modelo: código en Python que ajuste el modelo correspondiente.
4. Interpretación de los coeficientes: traduce los coeficientes del modelo a cantidades con sentido de negocio (no te quedes solo en el número crudo).

5. Conclusión de negocio: responde explícitamente la pregunta planteada por MiBolsillo, en un lenguaje comprensible para alguien sin formación estadística.
6. Limitaciones: menciona al menos una limitación o supuesto que deba tenerse en cuenta antes de tomar decisiones con base en tu análisis.

Para cada parte se te entrega, en este documento, el código en Python que genera los datos necesarios. Cópialo tal cual en tu notebook antes de empezar tu análisis — tu trabajo empieza en el planteamiento del modelo, no en la simulación de los datos.

Parte 1 — Crecimiento de usuarios tras la campaña de referidos

Modelo esperado: regresión exponencial

Variable respuesta: número de usuarios nuevos por día (conteo, crecimiento multiplicativo en el tiempo).

Hace 10 días, MiBolsillo lanzó una campaña de referidos: cada usuario que invita a un amigo y este se registra, recibe un bono en la app. El equipo de Marketing ha visto que el número de usuarios nuevos por día viene creciendo aceleradamente, y necesita saber qué tan rápido está creciendo para dos decisiones muy concretas: cuántos servidores adicionales contratar para soportar la app, y cuándo el equipo de soporte al cliente empezará a saturarse si no se refuerza.

Datos del ejercicio

Copia y ejecuta el siguiente código en tu notebook para obtener los datos con los que vas a trabajar:

```
import numpy as np
import pandas as pd

np.random.seed(31)

dias = np.arange(0, 11) # dia 0 a dia 10 desde el lanzamiento de la campaña
a_real, b_real = 120, 0.30
y_esperado = a_real * np.exp(b_real * dias)
ruido = np.random.normal(0, 1, size=len(dias)) * (y_esperado * 0.05)
usuarios_nuevos = np.clip(np.round(y_esperado + ruido), 1, None)

df_usuarios = pd.DataFrame({'dia': dias, 'usuarios_nuevos': usuarios_nuevos})
df_usuarios.head()
```

Preguntas guía

- ¿Cuál es la tasa de crecimiento diaria estimada, y cada cuántos días se está duplicando el número de usuarios nuevos por día?
- Si la tendencia se mantiene sin intervención, ¿cuántos usuarios nuevos se esperarían el día 20? ¿Qué tan confiable te parece esa proyección a ese horizonte?
- El equipo de Marketing quiere reportar el crecimiento como "aumentamos X usuarios nuevos por día" (un número fijo). Explica, con tus propias palabras y usando tu ajuste, por qué esa forma de reportarlo no es adecuada para este fenómeno.
- ¿Qué evento de negocio o de producto podría hacer que, en algún momento, este crecimiento deje de ser exponencial? ¿Cómo se vería reflejado eso en los datos?

Parte 2 — Riesgo de incumplimiento en microcréditos

Modelo esperado: regresión logística

Variable respuesta: incumplimiento del crédito (binaria: sí/no).

MiBolsillo lleva seis meses ofreciendo microcréditos dentro de la app. Antes de escalar el producto a nivel nacional, el área de Riesgo necesita un modelo que estime la probabilidad de que un solicitante incumpla su crédito, a partir de información que ya tiene disponible de cada usuario en el momento de la solicitud.

Datos del ejercicio

Copia y ejecuta el siguiente código en tu notebook para obtener los datos con los que vas a trabajar:

```
import numpy as np
import pandas as pd

np.random.seed(88)

n = 500
ingreso_mensual = np.random.normal(2200, 600, n).clip(min=400)      # miles de COP
monto_solicitado = np.random.normal(800, 300, n).clip(min=100)     # miles de COP
antiguedad_meses = np.random.normal(14, 7, n).clip(min=1)         # meses como usuario de la
app
uso_otros_productos = np.random.binomial(1, 0.4, n)                # 1 = usa otros productos
de MiBolsillo
pagos_tardios_historicos = np.random.poisson(0.8, n)               # pagos tardíos previos
dentro de la app

ing_c = (ingreso_mensual - 2200) / 600
mon_c = (monto_solicitado - 800) / 300
ant_c = (antiguedad_meses - 14) / 7
tar_c = (pagos_tardios_historicos - 0.8) / 1

b0, b_ing, b_mon, b_ant, b_uso, b_tar = -1.1, -0.8, 0.55, -0.6, -0.7, 0.65
logit = b0 + b_ing*ing_c + b_mon*mon_c + b_ant*ant_c + b_uso*uso_otros_productos + b_tar*tar_c
prob = 1 / (1 + np.exp(-logit))
incumplimiento = np.random.binomial(1, prob)

df_credito = pd.DataFrame({
    'ingreso_mensual': ingreso_mensual,
    'monto_solicitado': monto_solicitado,
    'antiguedad_meses': antiguedad_meses,
    'uso_otros_productos': uso_otros_productos,
    'pagos_tardios_historicos': pagos_tardios_historicos,
    'incumplimiento': incumplimiento
})

df_credito.head()
```

Preguntas guía

- a) De las cinco variables disponibles, ¿cuáles resultan estadísticamente significativas para predecir el incumplimiento? Traduce el odds ratio de cada una a una frase de negocio.
- b) Divide los datos en entrenamiento y prueba, entrena el modelo con scikit-learn, y evalúa su desempeño (exactitud, matriz de confusión y AUC). ¿El modelo comete más falsos positivos o más falsos negativos? ¿Cuál de los dos errores le preocuparía más al área de Riesgo de MiBolsillo, y por qué?
- c) Usa tu modelo para estimar la probabilidad de incumplimiento de un solicitante con ingreso mensual de 1.400 (miles de COP), monto solicitado de 1.200 (miles de COP), 4 meses de antigüedad en la app, que no usa otros productos, y con 2 pagos tardíos históricos. ¿Aprobarías su microcrédito?
- d) El área comercial de MiBolsillo propone aprobar automáticamente todo solicitante con probabilidad de incumplimiento menor al 50%. ¿Qué opinas de usar ese umbral fijo, considerando el volumen de solicitudes y el costo de cada tipo de error?

Entregables

- Un (1) archivo de Jupyter Notebook (.ipynb), con las dos partes resueltas en orden.
- El notebook debe poder ejecutarse de principio a fin sin errores (Kernel → Restart & Run All) antes de la entrega.
- Cada parte debe estar claramente delimitada con encabezados (celdas Markdown) y debe responder explícitamente todas las "preguntas guía" planteadas.